



FEED FORWARD NN

Asst.Prof.Dr.Supakit Nootyaskool
IT-KMITL



Learning Outcome

$$\forall \hat{m}_N \rightarrow 1 \quad \hat{m}_N \leq 1$$

- Understand how to implement MLP in N:N and 1:N model
- Know under and over-fitting problems *Data scaling*
- Have experience using iris data set
- Write code to train Iris data to nuralnet()

Topic

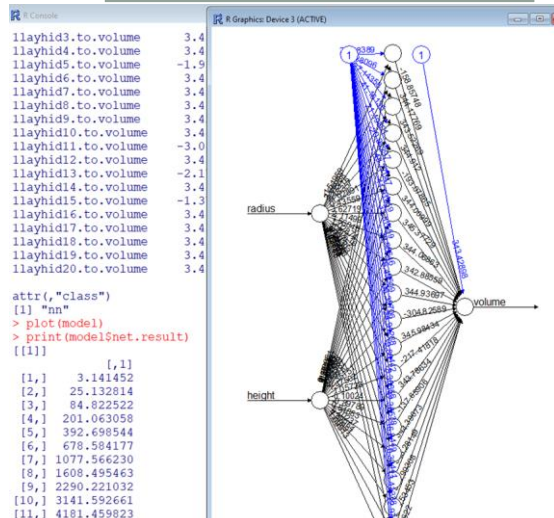

- Perceptron N:N model
- Perceptron 1:N model
- Input data adjustment
- Under and over-fitting
- Iris data set
- Train Iris data to nuralnet()

PERCEPTRON N:N, M:N, N:M


เพื่อให้เข้าใจการออกแบบ NN ในลักษณะที่แตกต่างออกไป

"คิดแตกต่างเป็นหนทางในการหาทางออก"

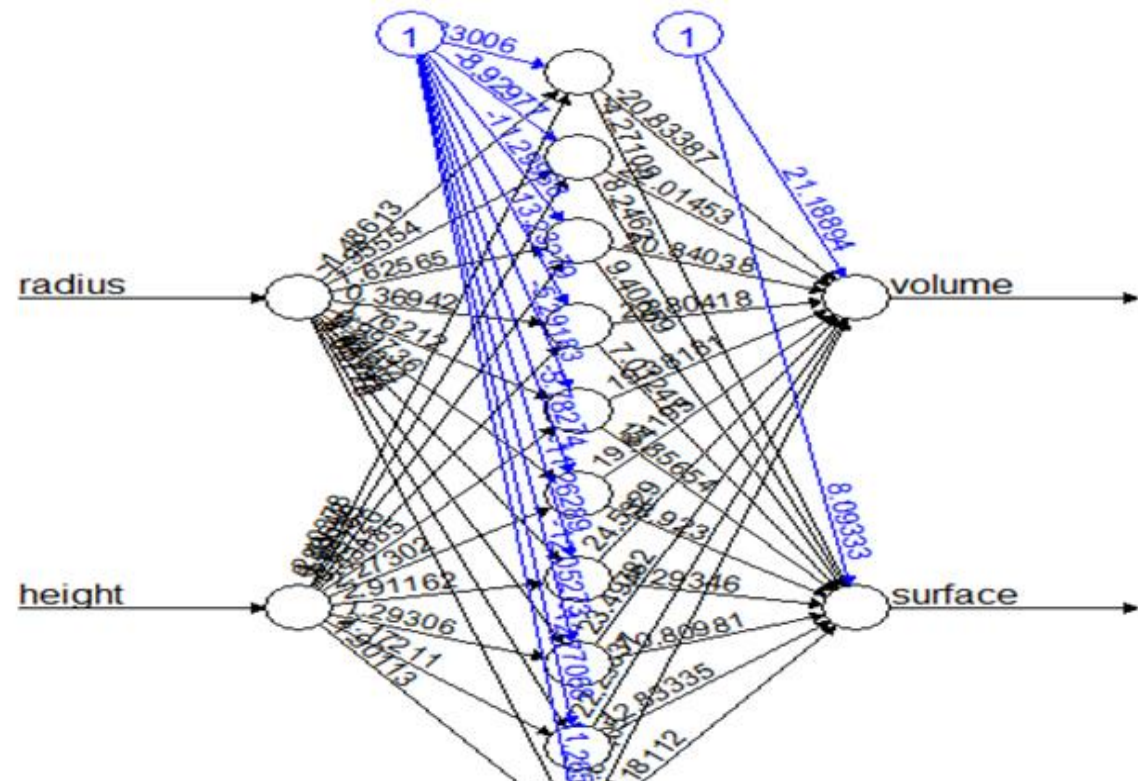
Models Neural Networks



5.1 Perceptron with N:N input = output



- Volume = $\pi * r * r * h$
- Surface = $2 * \pi * r * h$



Activity 5.1 N:N Perceptron

```
#####  
#ACTIVITY 5-1 N:N PERCEPTRON  
#VOLUME AND SURFACE OF CYLINDER CALCUATING  
#WITH PERCEPTRON  
#####
```

```
library("neuralnet")
```

```
radius = 1:4
```

```
height = 1:4
```

```
volume = pi*radius*radius*height
```

```
surface = 2*pi*radius*height
```

```
datatrain = data.frame(radius,height,  
                        volume,  
                        surface)
```


datatrain

```
model <- neuralnet(
  volume+surface~radius+height,
  datatrain,
  hidden=10, ##<--Change here
  rep = 1,
  linear.output = TRUE)
```

```
print(model)
```

```
plot(model)
```

```
print(model$net.result)
```



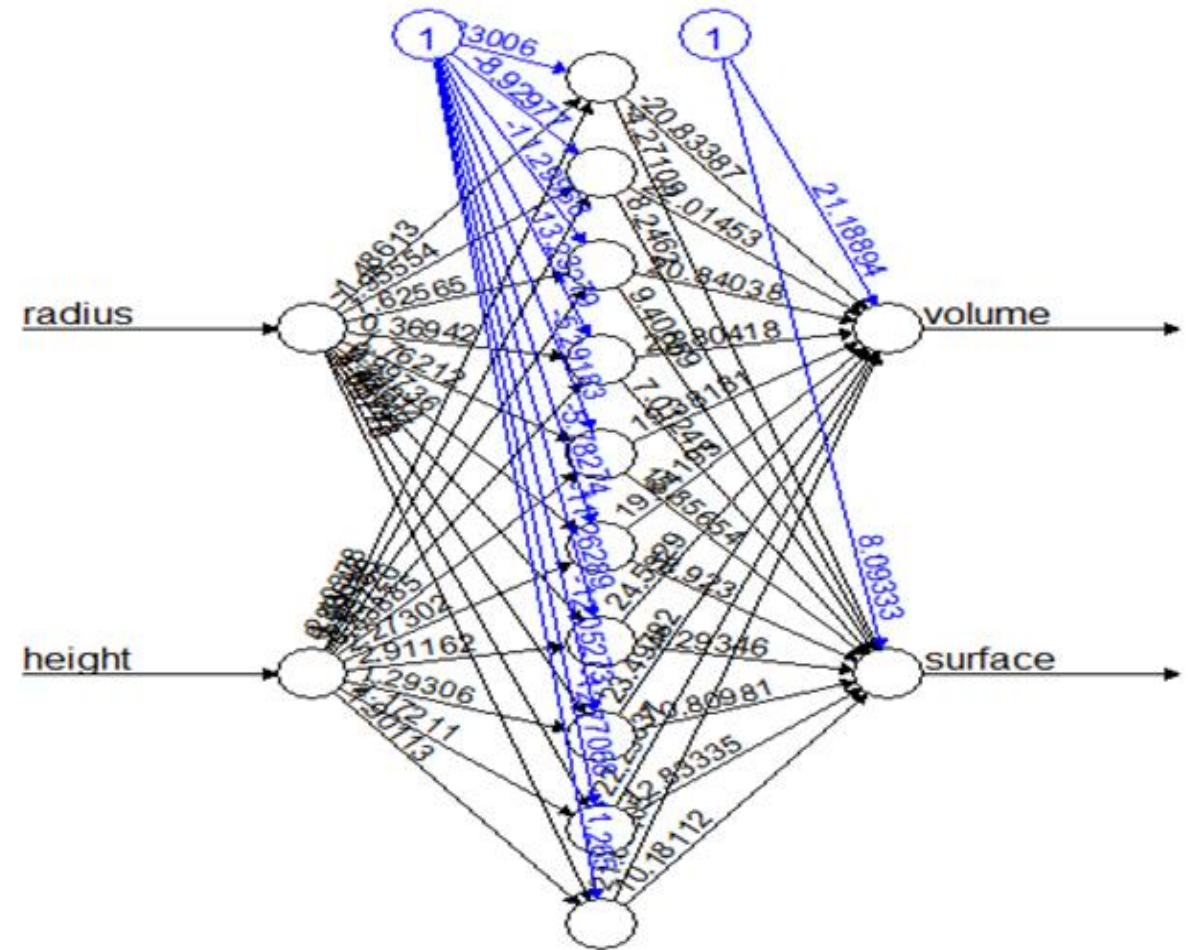
Activity 5.1 N:N Perceptron

\$data


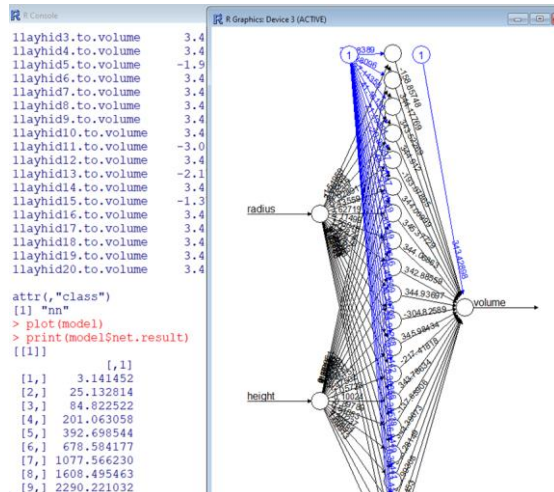

	radius	height	volume	surface
1	1	1	3.141593	6.283185
2	2	2	25.132741	25.132741
3	3	3	84.823002	56.548668
4	4	4	201.061930	100.530965

\$net.result[[1]]

	[,1]	[,2]
[1,]	3.13088	6.293871
[2,]	25.14182	25.122653
[3,]	84.82135	56.550207
[4,]	201.06319	100.531784



Models Neural Networks





- al output
-
- Diagram illustrating a neural network structure with 4 input nodes, 3 hidden nodes, and 4 output nodes. The network is fully connected. Weights are shown on the edges. Blue weights are highlighted.
- Input nodes: 1, 2
- Hidden nodes: 3, 4
- Output nodes: b0, b1, b2, b3
- Weights (Blue):
- Input 1 to Hidden 3: 2.12872
 - Input 1 to Hidden 4: 0.28302
 - Input 1 to Output b0: 4.26477
 - Input 1 to Output b1: 1.06308
 - Input 1 to Output b2: 1.81029
 - Input 1 to Output b3: -0.42263
 - Input 2 to Hidden 3: -3.01099
 - Input 2 to Hidden 4: 0.17619
 - Input 2 to Output b0: -0.21408
 - Input 2 to Output b1: 1.74367
 - Input 2 to Output b2: 6.63356
 - Input 2 to Output b3: 4.94358
- Weights (Black):
- Hidden 3 to Output b0: -0.21408
 - Hidden 3 to Output b1: 1.74367
 - Hidden 3 to Output b2: 6.63356
 - Hidden 3 to Output b3: 4.94358
 - Hidden 4 to Output b0: -0.21408
 - Hidden 4 to Output b1: 1.74367
 - Hidden 4 to Output b2: 6.63356
 - Hidden 4 to Output b3: 4.94358
- Other weights (Black):
- Input 1 to Hidden 3: 2.12872
 - Input 1 to Hidden 4: 0.28302
 - Input 1 to Output b0: 4.26477
 - Input 1 to Output b1: 1.06308
 - Input 1 to Output b2: 1.81029
 - Input 1 to Output b3: -0.42263
 - Input 2 to Hidden 3: -3.01099
 - Input 2 to Hidden 4: 0.17619
 - Input 2 to Output b0: -0.21408
 - Input 2 to Output b1: 1.74367
 - Input 2 to Output b2: 6.63356
 - Input 2 to Output b3: 4.94358

Flexcil - The Smart Study Toolkit & PDF, Annotate, Note

Activity 5.2 1:N, Perceptron


```
#####
#ACTIVITY 5-2 1:N PERCEPTRON
#ANALOG TO DIGITAL CONVERTER WITH
#PERCEPTRON
#####

library("neuralnet")

volt = c(1,2,3,4)
b0 = c(1,0,0,0)
b1 = c(0,1,0,0)
b2 = c(0,0,1,0)
b3 = c(0,0,0,1)
datatrain = data.frame(volt,b0,b1,b2,b3)
datatrain
```

```
model <- neuralnet(
  b0+b1+b2+b3~volt,
  datatrain,
  hidden=4, ##<--Change here
  rep = 1,
  linear.output = TRUE)

print(model)
plot(model)
print(model$net.result)
```



Activity 5.2 1:N, Perceptron


\$data

	volt	b0	b1	b2	b3
1	1	1	0	0	0
2	2	0	1	0	0
3	3	0	0	1	0
4	4	0	0	0	1

\$net.result



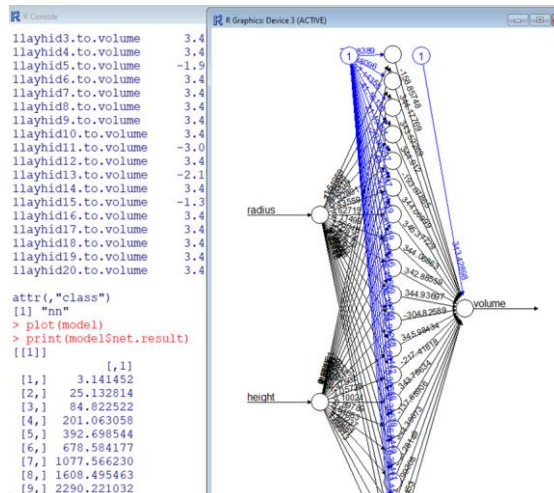

\$net.result[[1]]

	[,1]	[,2]	[,3]	[,4]
[1,]	1.00064948	0.001159281	-0.004748923	-0.02828780
[2,]	0.01309618	0.971998321	0.015997339	0.03412774
[3,]	-0.02652515	0.080825292	0.958267428	-0.01105141
[4,]	0.01457693	-0.060783183	0.024395649	0.99534282



Error: 0.005122 Steps: 1403

Summary: Models Neural Networks



DATA SCALING

เพื่อให้สามารถเขียนโปรแกรมในการปรับขนาดข้อมูลได้

To be able to write a computer code for the adjustment size of the data.

Data scaling


- Data scaling มีอีกชื่อ ^{การปรับขนาด} Normalization
- ปรับขนาดโดยยังคง ระยะห่าง ข้อมูลเหมือนเดิม
- ช่วยให้ ลดระยะทางในการค้นหาของ ML
- แก้ปัญหา สอนช้าใน ML
- ต้อง scale down ไม่ใช่ scale up




-100 to 100

Scaling

-1 to 1



รู้ขนาดแล้วจะได้ไม่




Scaling data




Scaling

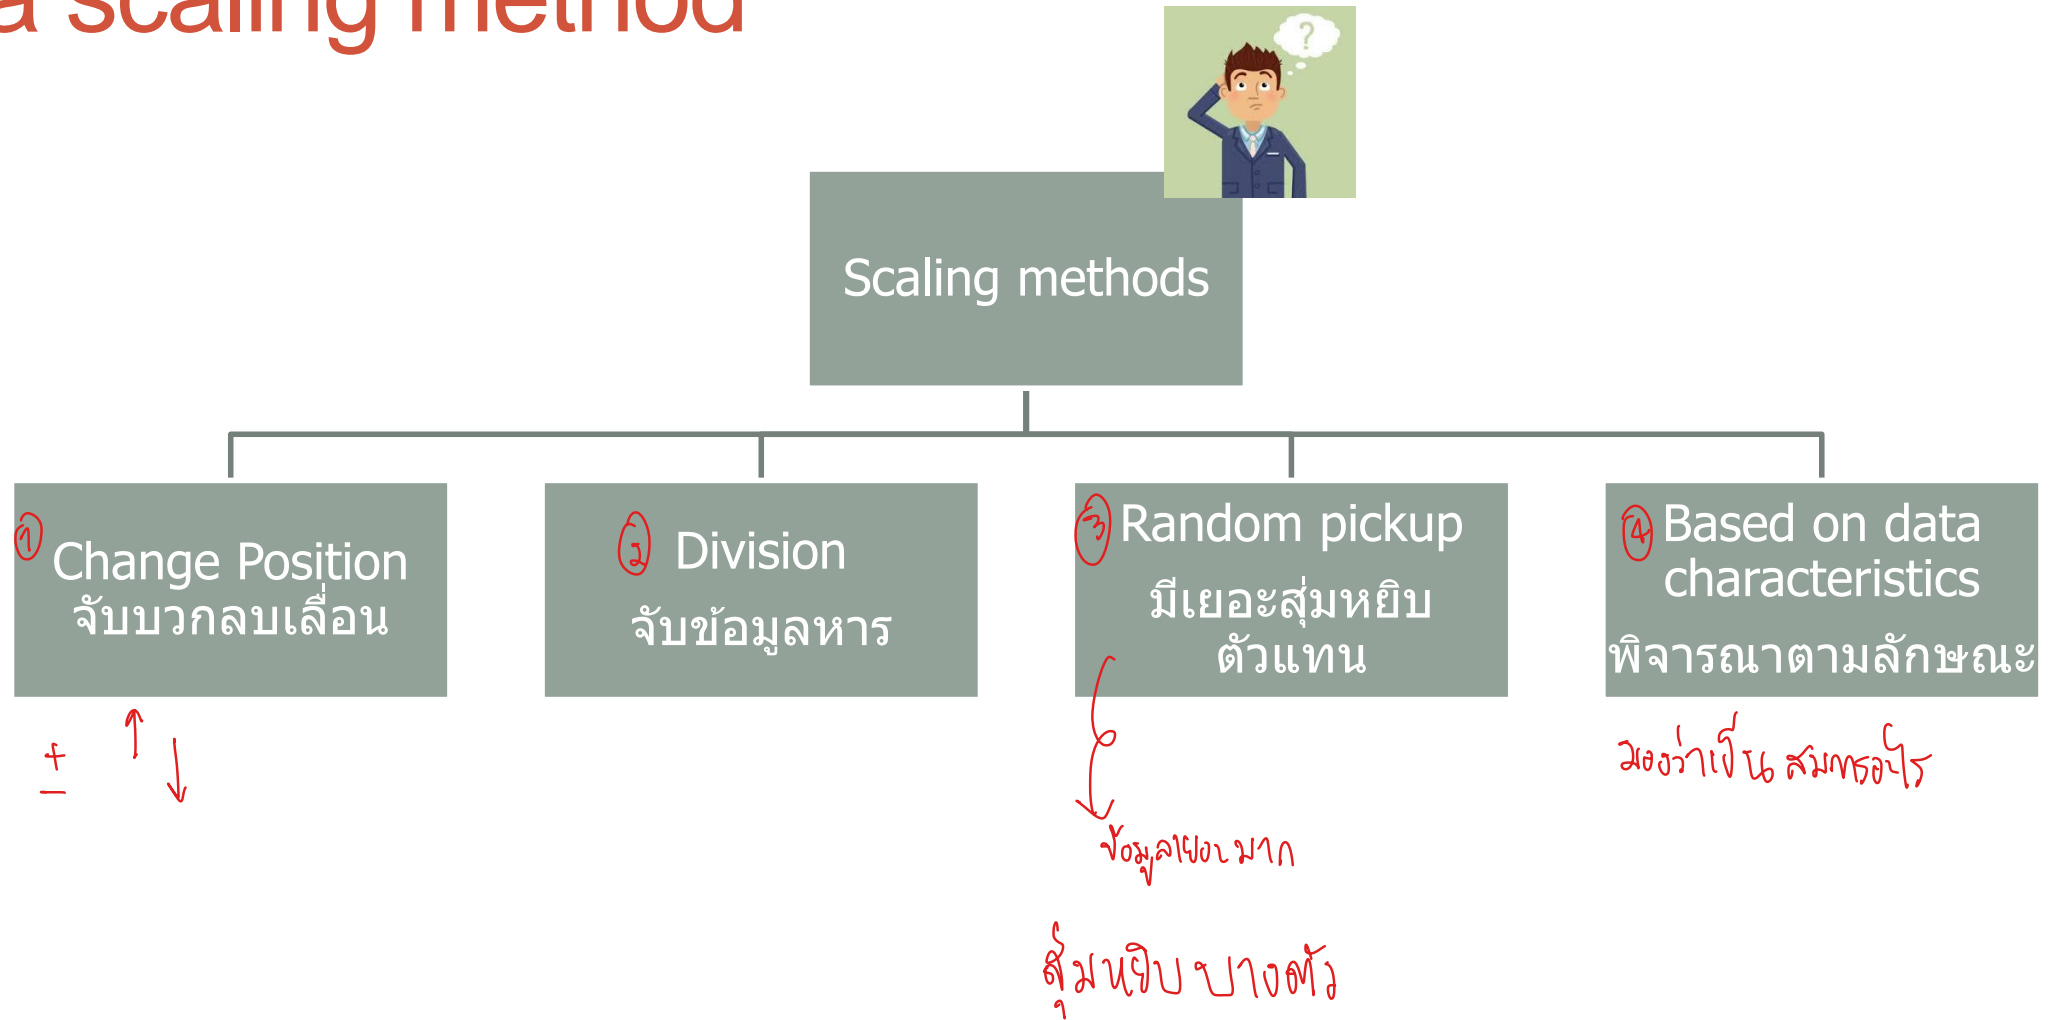
Raw data



Scaled data



Data scaling method



5.3.1 Z-score normalization

- ให้ค่าเฉลี่ยข้อมูลใหม่เป็น 0 $Z = \frac{X - \bar{X}}{SD}$
- ความห่างระหว่างสมาชิกเหมือนเดิม ต่างที่สัดส่วน
- ใช้สูตรนี้

```
> x = c(1, 2, 3, 4)
> sd(x)
[1] 1.290994
> x = c(11, 22, 33, 44)
> sd(x)
[1] 14.20094
```

$$z = (X - \mu) / \sigma$$

mean
ค่าเฉลี่ย


Standard Deviation
ค่าเบี่ยงเบนมาตรฐาน

มีใช้ปกและลบอยู่

5.3.1 Test Z-score function

```
funcZscore = function(x)
{
    avg = mean(x)
    sd = sd(x)
    z = (x - avg) / sd
    return(z)
}
```

```
x1 = runif(10,-10,10)
print(x1)
x2 = funcZscore (x1)
print(x2)
plot(x1,type='l', col='red')
lines(x2,col='blue')
```



$\sum \text{వాల్య} = 0$

5.3.2 Min-max normalization

- ลดขนาดให้อยู่ในกรอบ 0 ถึง 1
- ความห่างระหว่างสมาชิกเหมือนเดิม ต่างที่สัดส่วน
- ใช้สูตรนี้

อยู่ ช่วงปกติทั้งหมด ไม่เสียสเกล
Sig mold


$$Z_i = \frac{x_i - \min(x)}{\max(x) - \min(x)}$$

5.3.2 Test Min-Max function

อยู่ ช่วง ขว ท้องนม

```
funcMaxMin = function(x)
{
    minx = min(x)
    maxx = max(x)
    range = maxx-minx
    z = (x - minx) / range
    return(z)
}
```

```
x1 = runif(10,-10,10)
print(x1)
x2 = funcMaxMin(x1)
#x2 = scale(x1)
print(x2)
plot(x1,type='l', col='red')
lines(x2,col='blue')
```



5.3.3 Shift position

- ใช้การบวกเลขเพื่อเลื่อนตำแหน่งข้อมูล
- ความห่างระหว่างสมาชิกเหมือนเดิม ต่างที่สัดส่วน
- ใช้สูตรนี้



$$Z = X + c$$

↓
ค่าข้อมูล

constant value
ค่าคงที่

5.3.3 Shift position

```
x1 = runif(10,-10,10)
```


```
print(x1)
```

```
x2 = x1+5
```

```
print(x2)
```

```
plot(x1,type='l', col='red')
```

```
lines(x2,col='blue')
```



5.3.4 Ratio adjustment

- ใช้การคูณหรือหารเพื่อปรับขนาดข้อมูล
- ความห่างระหว่างสมาชิกเหมือนเดิม ต่างที่สัดส่วน
- ใช้สูตรนี้

$$z = X * c$$

constant value
ค่าคงที่

5.3.4 Ratio adjustment

```
x1 = runif(10,-10,10)
```

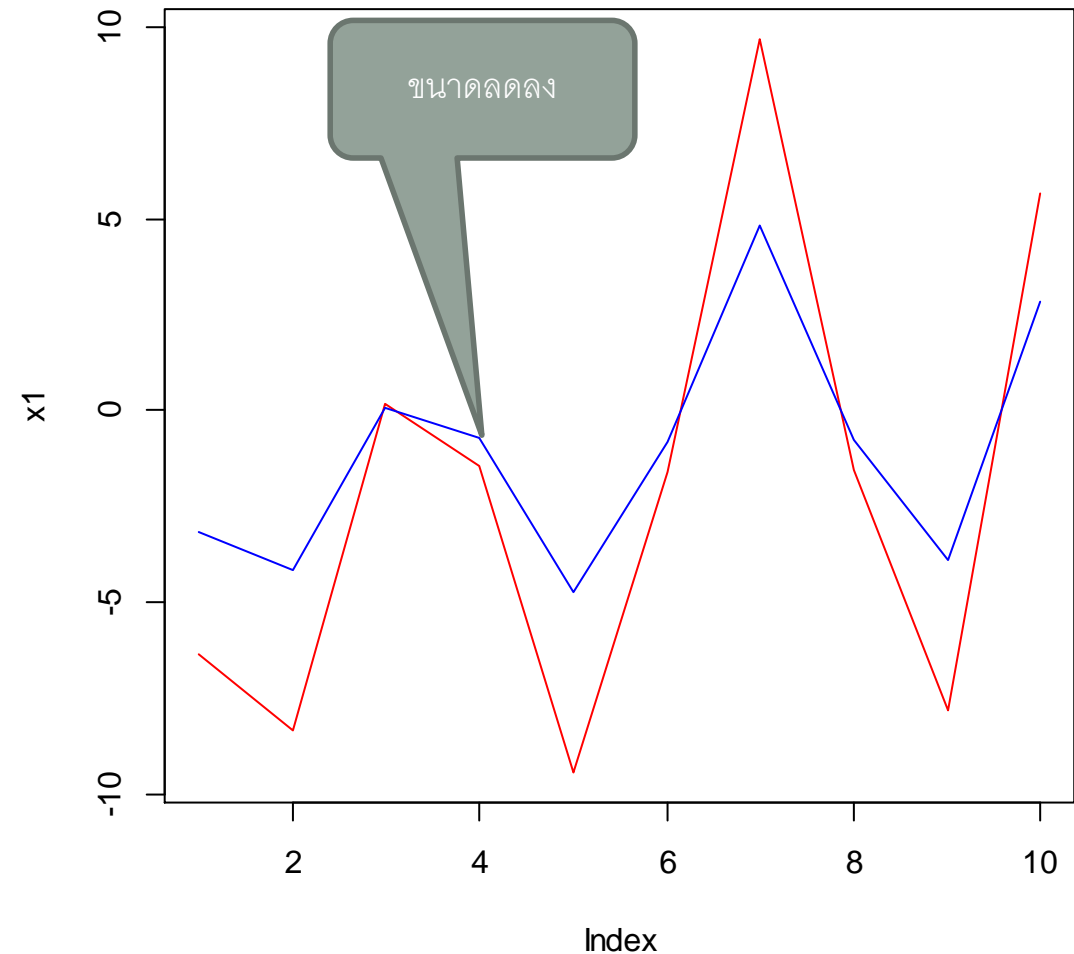
```
print(x1)
```

```
x2 = x1*0.5
```

```
print(x2)
```

```
plot(x1,type='l', col='red')
```

```
lines(x2,col='blue')
```



5.3.5 Zero-Sum Normalization


- ผลรวมของสมาชิกมีค่าเป็น 0 (บางที่ใช้ 1)
- ความห่างระหว่างสมาชิกต่างไปไม่เป็นสัดส่วนเดิม
- ใช้สูตรนี้

$$z = \frac{X}{\sum X} + c$$

constant value
ค่าคงที่

5.3.5 Zero-sum normalization

```
x1 = runif(10,-10,10)
print(x1)
funcNormlization = function(x)
{
    sumx = sum(x)
    z = x/sumx
    return(z)
}
x2 = funcNormlization(x1)
print(x2)
plot(x1,type='l', col='red')
lines(x2,col='blue')
```



Excellent data scaling

$A = A$ เหมือนกันไหม?

วิธีการปรับขนาดที่ดีคือ

- ลดหรือเพิ่มแต่ขนาด
- คงความสัมพันธ์ของสมาชิกไว้ ใช้ **Pearson's correlation** พิสูจน์

Pearson's Correlation

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Scale of correlation
coefficient

Value

$0 < r \leq 0.19$

Very Low
Correlation

$0.2 \leq r \leq 0.39$

Low Correlation

$0.4 \leq r \leq 0.59$

Moderate
Correlation

$0.6 \leq r \leq 0.79$

High Correlation

$0.8 \leq r \leq 1.0$

Very High
Correlation

1 เหมือน

0 ไม่เหมือน

Example code:

```

amount = 1000
lowerbound = -1000
upperbound = 1000
data =runif(amount,lowerbound,upperbound )
plot(data)

mean(data)
sd(data)

#####REDUCE SIZE#####
data_reducedsize = data/1000
mean(data_reducedsize)
sd(data_reducedsize)

#####Z-SCORE#####
funcZscore = function(x)
{
    avg = mean(x)
    sd = sd(x)
    z = (x - avg) / sd
    return(z)
}
data_applied_zscore = funcZscore(data)
mean(data_applied_zscore)
sd(data_applied_zscore)

```

```

{
    minx = min(x)
    maxx = max(x)
    range = maxx-minx
    z = (x - minx) / range
    return(z)
}
data_applied_minmax = funcMaxMin (data)
mean(data_applied_minmax )
sd(data_applied_minmax )

#####NORMALIZATION FUNC#####
funcNormlization = function(x)
{
    sumx = sum(x)
    z = x/sumx
    return(z)
}
data_applied_norm = funcNormlization (data)
mean(data_applied_norm )
sd(data_applied_norm )

#####
install.packages("ggpubr")
library("ggpubr")
cor(data,data)
cor(data,data_reducedsize)
cor(data,data_applied_zscore)
cor(data,data_applied_minmax)
cor(data,data_applied_norm)

summary(data)
summary(data_reducedsize)
summary(data_applied_zscore)
summary(data_applied_minmax)
summary(data_applied_norm)

```

library สำหรับ
Pearson's correlation

```
> summary(data)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-997.433	-513.745	13.417	8.569	523.796	994.770

```
> summary(data_reducedsize)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-0.997433	-0.513745	0.013417	0.008569	0.523796	0.994771

```
> summary(data_applied_zscore)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-1.739737	-0.903267	0.008385	0.000000	0.891012	1.705494

```
> summary(data_applied_minmax)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.0000	0.2428	0.5074	0.5050	0.7636	1.0000

```
> summary(data_applied_norm)
```


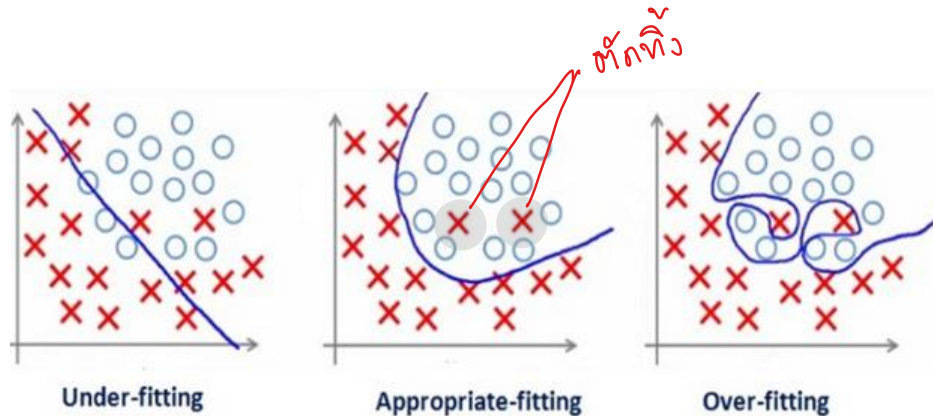
Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-0.116401	-0.059954	0.001566	0.001000	0.061127	0.116090

UNDERFITTING – OVERFITTING

เพื่อให้รู้จักปัญหาการสอน ML ดีเกินไปและสอนไม่ดีเกินไป

To recognize a problem of ML training by overfitting and underfitting

5.4.1 Under and Over-fitting



- จับ ๑ แบบเดิมมากเกินไป ๑ ไม่รู้เรื่องอะไรดี
- การสอนที่มุ่งให้ Low error มักจะเกิด
ปัญหา **Overfitting** แก้โดยรู้มกในใจจริงๆ ไม่เอา ๑ แบบเดิม
 - กลับกัน สอนที่ไม่ได้ High error ก็เกิด
ปัญหา **Underfitting** กกกก (จ) ? สงสัย
เกิดจากใส่ข้อมูลผิด เลือกข้อมูลไม่ดี
 - ปัจจัยให้เกิด
 - ลักษณะ model ML
 - ลักษณะข้อมูล กระจายไป
 - ลักษณะข้อมูล มีส่วนผิดที่ครมเครือมากผสม
 - โปรแกรมเมอร์/นักวิจัย ทำผิดเอง

5.4.2 The method reduce overfitting

- NN เกิด overfitting ได้
- แก้โดยหยุดสอนก่อนได้ค่า error ต่ำมากๆ 0.01
0.09 0.1
- นำ data ที่แตกต่างกันมาใส่ให้รู้จัก ก ก ก ก ก ก
- ไม่ใช่ target เดียว ต้องสุ่มเลือก target เพื่อสร้าง ความหลากหลาย
- ใช้หลาย NN ช่วยตัดสินใจโดยการเฉลี่ย ไม่ใช่ตัวเดียว
 - Example AI in MAR spaceship project มีหลาย model
model ก model ข model ค model ง

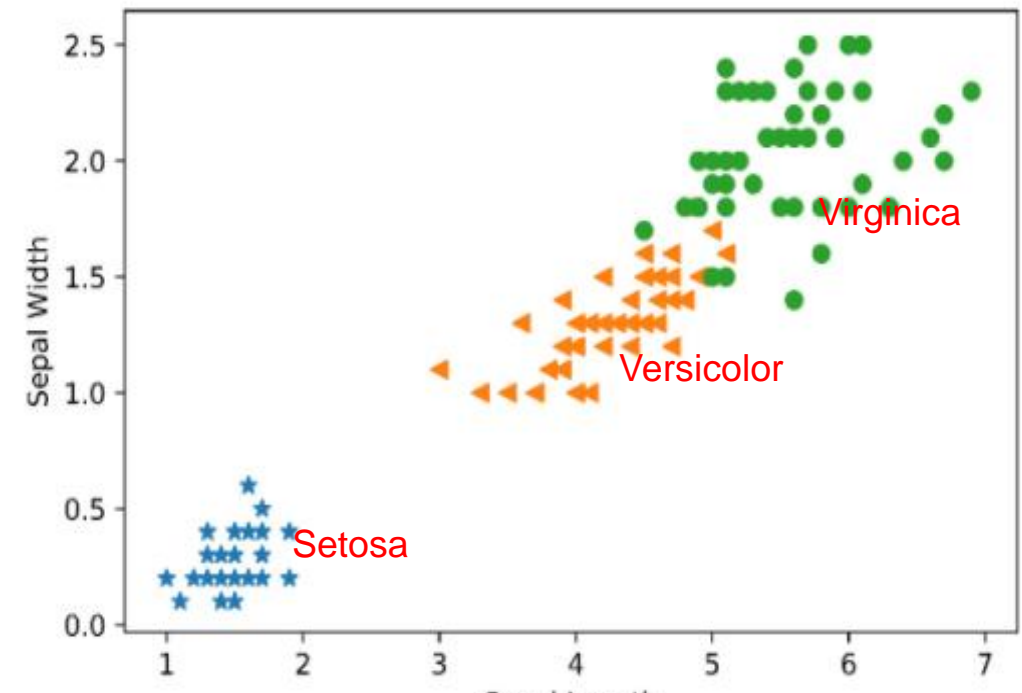
IRIS DATASET

เพื่อมีประสบการณ์ใช้ NN แยกชนิดดอกไม้

To experience the usage NN recognize the flower


5.5 Iris dataset

- IRIS dataset ไอริสดำต๋า นิยมใช้กันมาก
- ข้อดีทำให้มี comparator ว่างงานวิจัย
- หา download ได้ฟรี
- คนสร้างเขาวัดขนาดของใบ Width, Length และ
ระบุชนิดไว้เป็น target
- ข้างในประกอบด้วย
 - Setosa ซี้โทซา
 - Virginica วีจินิกา
 - Versicolor เวสคัลเลอร์



5.5.1 Iris dataset

- 5-column in data set
 - Sepal length
 - Sepal width
 - Petal length
 - Petal width
 - Class label



Activity 5.5 Load Iris data set

```
#LOAD DATA
```

```
data(iris)
```

```
#PRINT SUMMARY
```

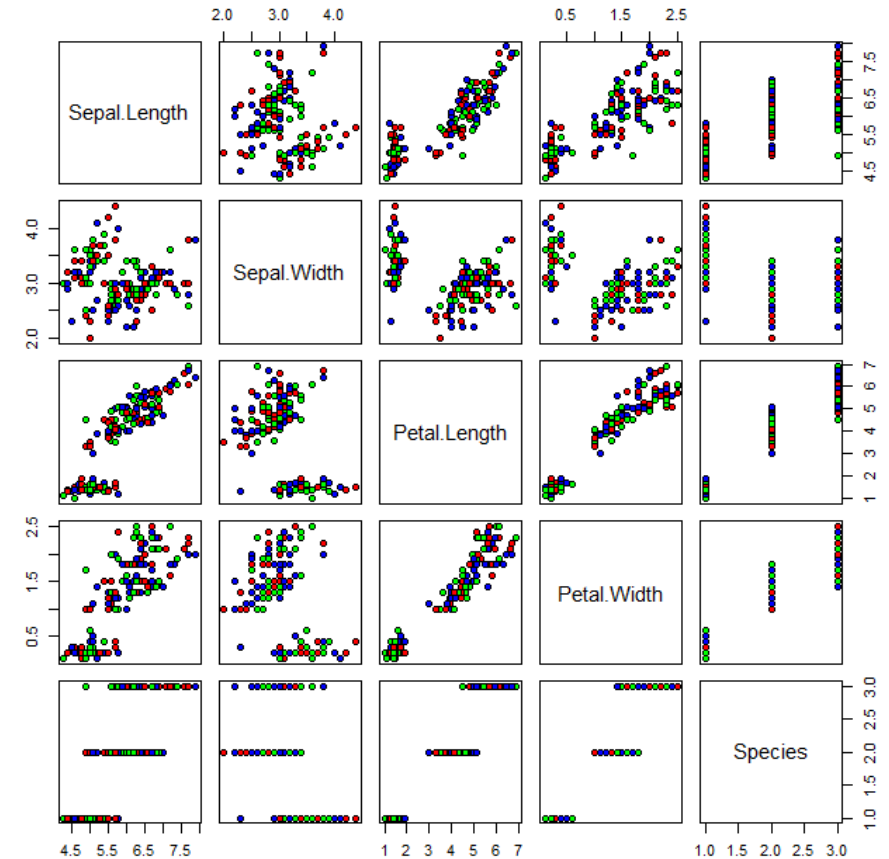
```
summary(iris)
```

```
#PLOT
```

```
plot(iris,
     bg = c("red", "green", "blue"), pch=21)
```

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min. :4.300	Min. :2.000	Min. :1.000	Min. :0.100
1st Qu.:5.100	1st Qu.:2.800	1st Qu.:1.600	1st Qu.:0.300
Median :5.800	Median :3.000	Median :4.350	Median :1.300
Mean :5.843	Mean :3.057	Mean :3.758	Mean :1.199
3rd Qu.:6.400	3rd Qu.:3.300	3rd Qu.:5.100	3rd Qu.:1.800
Max. :7.900	Max. :4.400	Max. :6.900	Max. :2.500

Species
setosa :50
versicolor:50
virginica :50



Data specification.

Width:	0.1 to 12.5
Length:	1.0 to 7.9
Unit:	Centimeter
setosa:	50 items
versicolor:	50 items
virginica	50 items

Activity 5.5 Load Iris data set

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
23	4.6	3.6	1.0	0.2	setosa
132	7.9	3.8	6.4	2.0	virginica
38	4.9	3.6	1.4	0.1	setosa
44	5.0	3.5	1.6	0.6	setosa
94	5.0	2.3	3.3	1.0	versicolor
141	6.7	3.1	5.6	2.4	virginica
129	6.4	2.8	5.6	2.1	virginica
65	5.6	2.9	3.6	1.3	versicolor
138	6.4	3.1	5.5	1.8	virginica
53	6.9	3.1	4.9	1.5	versicolor
89	5.6	3.0	4.1	1.3	versicolor
71	5.9	3.2	4.8	1.8	versicolor
18	5.1	3.5	1.4	0.3	setosa
35	4.9	3.1	1.5	0.2	setosa
30	4.7	3.2	1.6	0.2	setosa
111	6.5	3.2	5.1	2.0	virginica
134	6.3	2.8	5.1	1.5	virginica
125	6.7	3.3	5.7	2.1	virginica
16	5.7	4.4	1.5	0.4	setosa
10	4.9	3.1	1.5	0.1	setosa

```
s = sample(1:150,20)
siris = iris[s,]
siris
```

- 20 sample data from 150 data to check data details.

5.6 Iris dataset on neuralnet()

```
#####
#ACTIVITY 5-6 IRIS DATA SET ON NEURALNET
#####

#PREPARING DATA
data(iris)
head(iris)          #CHECK COLUMN NAME
#Sepal.Length Sepal.Width Petal.Length
#Petal.Width Species

#CHEANGING setosa=1, versicolor=2, virginica=3
datatrain = data.frame(iris)

datatrain$Species =
    c(rep(1,50),rep(2,50),rep(3,50))
datatrain
```

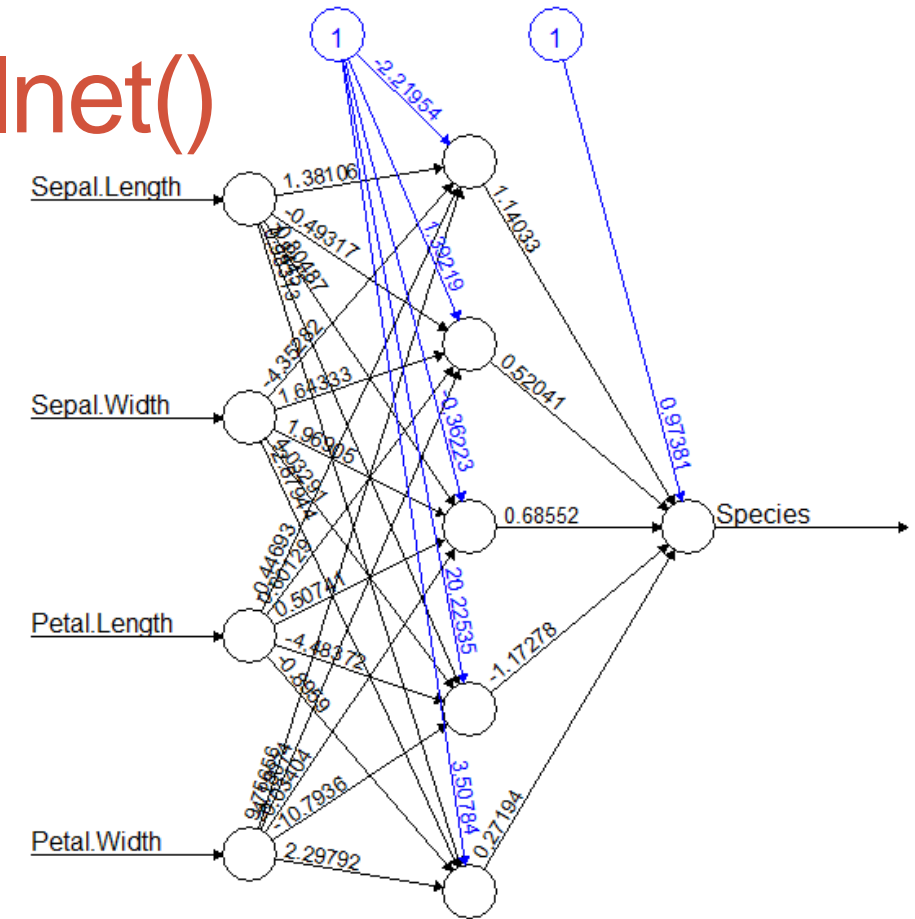
```
#TRAINING
library("neuralnet")
model <- neuralnet(
    Species~Sepal.Length+
    Sepal.Width+Petal.Length+Petal.Width,
    datatrain,
    hidden=5, ##<--Change here
    rep = 1,
    linear.output = TRUE)

print(model)
plot(model)
print(model$net.result)
```

- Before training, Iris at Specie column need to change from text to integer value.

Activity 5.6 Iris dataset on neuralnet()

[1,] 0.9969690	[50,] 0.9980830	[100,] 2.0139561
[2,] 1.0029164	[51,] 2.0070355	[101,] 2.9829099
[3,] 1.0000290	[52,] 1.9818641	[102,] 3.0250643
[4,] 0.9999288	[53,] 1.9961415	[103,] 3.0182555
[5,] 0.9974936	[54,] 1.9471998	[104,] 3.0470866
[6,] 0.9993556	[55,] 1.9719388	[105,] 3.0133043
[7,] 1.0007880	[56,] 2.0322993	[106,] 3.0183982
[8,] 0.9971131	[57,] 1.9834482	[107,] 2.8782836
[9,] 1.0044037	[58,] 1.9884696	[108,] 3.0609974
[10,] 0.9938142	[59,] 2.0204959	[109,] 3.0246080
[11,] 0.9962128	[60,] 1.9840318	[110,] 2.9798797
[12,] 0.9974919	[61,] 1.9744310	[111,] 2.9442357
[13,] 0.9954311	[62,] 1.9694776	[112,] 3.0172917
[14,] 0.9988545	[63,] 1.9758656	[113,] 3.0164156
[15,] 0.9962150	[64,] 2.0254515	[114,] 3.0161623
[16,] 1.0008009	[65,] 2.0003704	[115,] 3.0198175
[17,] 0.9997327	[66,] 1.9942003	[116,] 3.0076843
[18,] 0.9999851	[67,] 2.0108983	[117,] 3.0110507
[19,] 0.9971749	[68,] 1.9706303	[118,] 2.9820601
[20,] 0.9991712	[69,] 2.1106838	[119,] 2.9852588
[21,] 0.9951246	[70,] 2.0278231	[120,] 2.8225728
[22,] 1.0002536	[71,] 2.4424848	[121,] 3.0101465
[23,] 0.9991591	[72,] 1.9969952	[122,] 3.0158055
[24,] 1.0114278	[73,] 2.3219683	[123,] 3.0178016
[25,] 0.9972057	[74,] 2.0468231	[124,] 2.8725434
[26,] 1.0008031	[75,] 2.0120565	[125,] 3.0049854
[27,] 1.0033269	[76,] 1.9879417	[126,] 3.0413179
[28,] 0.9963930	[77,] 1.9879632	[127,] 2.7529642
[29,] 0.9969794	[78,] 2.3297510	[128,] 2.7141460
	[79,] 1.9941549	[129,] 3.0196588



- Target
 - setosa=1
 - versicolor=2,
 - virginica=3

Summary ทำ Quiz วันพุธตอน 20.00น.

ทำโจทย์ง่าย ๆ 3-4 Variable มา Train กับ NN และทดสอบ Recognize

→ ส่งไฟล์ PDF A4 1 หน้า Upload ส่ง ก่อน 19.00น